

Atlas da Migração Interna no Brasil — Censo 2022 (data fixa)

Projeto: migracoes-fluxo-saldo-br · Dados: IBGE, Censo Demográfico 2022, microdados da amostra (acesso controlado)

Contexto

Construir, a partir dos microdados de **acesso controlado** da amostra do Censo 2022 (27 UFs, 21,5 milhões de registros de pessoas, 8,8 GB em CSV ;), um atlas interativo da migração intermunicipal brasileira no quinquênio 2017–2022, usando o quesito de **data fixa** (município de residência em 31/07/2017). O produto final é um dashboard web público com: saldo migratório e taxas por município, matriz completa de fluxos origem→destino entre os 5.570 municípios, perfil dos migrantes por escolaridade, renda e status migratório (inclusive migração de retorno), seleção de fluxo no mapa com perfil dos migrantes daquele par, e uma **seção exclusiva para regiões metropolitanas** com fluxos migratórios intrametropolitanos, perfil dos migrantes e fluxos origem→destino de **deslocamento pendular** (trabalho e estudo) com caracterização completa. O trabalho é grande, então o plano é **escalonado em 9 fases** com entregáveis independentes, e prevê a **orquestração de modelos Claude** por tipo de tarefa para otimizar custo.

Diretório do projeto (vazio): `/Users/danielpessini/Documents/Code/estudos-pesquisa/migracoes-fluxo-saldo-br` Microdados:

`/Users/danielpessini/Documents/Microdados/microdados_censo_amostra_2022_csv_20260901_170814`

Decisões já tomadas com o usuário

Tema	Decisão
Renda	Rendimento domiciliar per capita (D0360, join Domicilios↔Pessoas por <code>P0100=D0100</code>), em classes de salário mínimo (R\$ 1.212)
Publicação	Site estático público (GitHub Pages/Vercel). Só agregados saem do computador; regras de revelação aplicadas
Origem ignorada (9999999/8888888, ~1,8% dos migrantes)	Mantida como "origem não informada": conta na imigração total do destino, fica fora da matriz e da emigração; saldo calculado com origens conhecidas (Σ imigrantes conhecidos = Σ emigrantes)
Stack web	Vite + React + TypeScript + deck.gl/MapLibre + DuckDB-WASM + Observable Plot/D3
Pipeline	Python 3.14 + DuckDB (SQL sobre os CSVs, saída em Parquet). Pandas 3.0/openpyxl já instalados; instalar <code>duckdb</code> , <code>pyarrow</code> em venv

Fatos verificados na documentação e nos dados (fundamentam o desenho)

- Arquivos:** `<UF>/Pessoas_<UF>_controlado.csv` (341 colunas P0010...MP1220), `Domicilios`, `Familia`, `Mortalidade`; separador `;`, cabeçalho na 1ª linha, decimais com ponto. Layout em `Layout Microdados CD2022 - acesso Controlado.xlsx` (abas DOMI/PESS/MORT/FAMI).

- **Geografia:** P0080 município (7 dígitos IBGE), P0090 área de ponderação (APOND, menor nível permitido), P0060 RGI, P0050 RGInt, P0020 UF. Tabela de recortes: `Municípios_BR_Recortes_Territoriais_2022.xlsx` (5.570 municípios + RGI/RGInt/meso/micro/concentração urbana).
- **Peso:** P0111 (13 casas decimais; não arredondar). Validado: soma no DF = 2.817.381 = população oficial. Total Brasil esperado = 203.080.756 (Notas 04/2026, Tabela 3).
- **Data fixa:** P0600 (1 neste município, 2 outro município do Brasil, 3 outro país, branco = morava há 6+ anos no município **ou** menor de 5 anos), P0610 UF há 5 anos (88 não sabe, 99 ignorado), P0620 município há 5 anos (7 dígitos; 8888888 não sabe, 9999999 ignorado), P0630 país (10 dígitos; 8000999000 não sabe; 9999999999 ignorado). Só respondido por quem mora há **menos de 6 anos** no município (quesito 11.05 < 6) — fluxo do questionário confirmado (bloco 11).
- **Todos os códigos de P0620 observados existem na lista de 2022** (nenhum município criado entre 2013 e 2022 → grade 2017 = grade 2022; não há harmonização territorial a fazer).
- **Naturalidade/retorno:** P0480 (1 neste município, 2 outro município, 3 outro país), P0490 UF nasc., P0500 município nasc., P0520 nacionalidade (1 nato, 2 naturalizado, 3 estrangeiro). No DF: 13,6% dos imigrantes de data fixa são retornados ao município natal; 48% saíram do município natal no período; 2,7% origem ignorada.
- **Escolaridade:** P0770 (4 níveis compatíveis com 2010) e P0760 (7 níveis); ambas preenchidas para 100% das pessoas. P0790 anos de estudo.
- **Renda:** D0360 per capita (branco em domicílios coletivos, D0130=06); P1110 todas as fontes (branco < 10 anos; 0 = sem rendimento). Join 1:1 P0100 ↔ D0100 validado (100% casam).
- **Idade:** P0181 (anos simples). P0150/P0160 sexo. Marcas de imputação MP0600, MP0620 (~10% dos P0620 imputados no DF) — guardar como flag.
- **Precisão:** IBGE não fornece estratos/UPAs; recomenda FGV: $cv \approx A \cdot t^B$, pessoas Brasil $A=4,0616$, $B=-0,5004$ ($t=1.000 \rightarrow 12,8\%$; $t=100 \rightarrow 40\%$). Plano amostral: seleção de domicílios com equiprobabilidade dentro de setor, calibração por APOND, subamostra de 50% em setores com fração 100% (microdado controlado é recalibrado).
- **Confidencialidade (Notas 03/2026):** proibido redistribuir os arquivos; uso restrito à finalidade declarada; resultados podem divergir do SIDRA. Agregados são o produto esperado; células que individualizem devem ser omitidas ("x").
- Volume estimado: migrantes de data fixa $\approx 4-9\%$ dos registros por UF ($\approx 1,0-1,5$ milhão de linhas no Brasil); pares origem→destino distintos estimados em 150-300 mil.
- **Recortes metropolitanos** (`Municípios_BR_Recortes_Territoriais_2022.xlsx`): `COD_CATMETROPOL/NOME_CATMETROPOL` = 81 RMs e RIDEs (1.388 municípios; inclui RMs estaduais pouco funcionais, p.ex. "RM do Extremo Oeste" com 49 municípios), `COD_RECAU` = 3 aglomerações urbanas, `CodConcUrbana` = 186 concentrações urbanas (arranjos populacionais funcionais do IBGE, 660 municípios).
- **Deslocamento pendular para trabalho** (pessoas ocupadas de 10+ anos, semana de referência): P1120 local de trabalho (1 em casa, 2 fora de casa no município, 3 outro município, 4 outro país, 5 mais de um município, 9 ignorado), P1130 UF, P1140 município de trabalho (7 dígitos; ~2,4% com 8888888/9999999), P1150 país, P1160 retorna para casa 3+ dias na semana ($\approx 72\%$ sim no AP; o "não" identifica pendularidade semanal/longa), P1170 meio de transporte (14 categorias), P1180 tempo em classes, P1190 tempo em minutos (mediana ≈ 60 min no AP; outliers tratados pelo IBGE via CANCEIS, Notas 05 p. 57), MP1140 imputação (~9%). Perfil disponível: P1020 posição/formalidade, P1030 setor, P1040 grande grupo ocupacional, P1080 rendimento do trabalho. O IBGE corrigiu deterministicamente o erro do DMC com municípios homônimos (Notas 05 p. 57).

- **Deslocamento para estudo** (pessoas que frequentam escola): P0800 (1 neste município, 2 outro município, 3 outro país), P0810 UF, P0820 município (7 dígitos), P0830 país; nível do curso em P0660. Não há transporte/tempo para estudo.
- Teste de sanidade no AP: par pendular dominante Santana→Macapá (527 obs.), como esperado.

Definições metodológicas (a registrar em docs/METODOLOGIA.md)

Universo: pessoas de 5 anos ou mais residentes em 2022. **Migrante de data fixa** = P0600 = 2 (intermunicipal) ou 3 (internacional). Não migrante = P0600 em branco com idade ≥ 5 , ou P0600 = 1.

Por município i (pesos P0111):

- Imigrantes internos $I_i = \sum w$ com P0080 = i, P0600 = 2, P0620 $\notin \{8888888, 9999999\}$; I_i^{ni} = idem com origem não informada (exibido à parte); $I_i^{int} = P0600 = 3$.
- Emigrantes $E_i = \sum w$ com P0620 = i, P0080 $\neq i$, P0600 = 2.
- Saldo $S_i = I_i - E_i$; taxas por mil sobre a população de 5+ em 2022 (TBI, TBE, TLM); Índice de Eficácia Migratória $IEM = (I - E) / (I + E)$; participação de retorno.
- Fluxo $F_{\{o \rightarrow d\}} = \sum w$ com P0620 = o, P0080 = d, $o \neq d$; sempre acompanhado de n (observações não ponderadas) e se.

Status migratório (categorias mutuamente exclusivas, para P0600 $\in \{2, 3\}$):

1. Retorno ao município natal: P0480 = 1 e P0600 = 2.
2. Primeira saída do município natal: P0480 = 2 e P0620 = P0500.
3. Migração de etapas múltiplas: P0480 = 2, P0620 $\neq$ P0500, P0620 conhecido.
4. Imigração internacional: P0600 = 3, subdividida em brasileiros (P0520 $\in \{1, 2\}$, retorno do exterior) e estrangeiros (P0520 = 3). Flag adicional: retorno à UF natal (P0490 = P0020 e P0610 $\neq$ P0020) e interestadual vs intraestadual (P0610 $\neq$ P0020).

Escolaridade: P0770 (4 níveis), calculada para migrantes de **25 anos ou mais**; P0760 guardado para detalhe. **Renda:** D0360 em 5 classes de SM: sem rendimento/até ¼; ¼–½; ½–1; 1–2; >2 SM (cortes ajustáveis em config); domicílios coletivos = "não aplicável". **Idade/sexo** (extra de baixo custo, padrão em atlas): 5–14, 15–24, 25–39, 40–59, 60+ $\times$ sexo.

Precisão: estimador de conglomerados últimos com domicílio como UPA e APOND como estrato (prática consagrada para microdados do Censo, conservador por ignorar CPF e ganho de calibração): $Var(\hat{Y}) = \sum_h n_h / (n_h - 1) \cdot \sum_{\{i \in h\}} (z_{hi} - \bar{z}_h)^2$, $z_{hi} = \sum_{\{k \in i\}} w_k y_k$, n_h = domicílios amostrados na APOND (contado em Domicilios). Só domicílios com migrantes têm $z \neq 0$, logo $\sum z^2$ e $\sum z$ vêm de um único GROUP BY sobre os migrantes; n_h vem da tabela de domicílios. Cross-check com a FGV do IBGE. Classes (Guia IBGE 2021): CV $\leq 15\%$ boa; 15–30% cautela; > 30% baixa precisão (exibida com hachura/dessaturação).

Controle de revelação para publicação: todas as tabelas publicadas passam pelas regras R1–R9 da seção "Conformidade com a política de acesso controlado do IBGE" (limiar mínimo de observações, supressão complementar, arredondamento, faixas de n, gate automatizado); nenhum arquivo de data/raw ou data/interim sai da máquina; só data/processed (agregados aprovados pelo gate) vai para o site.

Módulo metropolitano

Recorte: padrão = RMs e RIDEs institucionais (`COD_CATMETROPOL` , 81 unidades), ordenadas por população e com busca; alternativa por toggle = Concentrações Urbanas (`CodConcUrbana` , recorte funcional do IBGE). **Núcleo** = município-sede (capital ou município mais populoso), registrado em `pipeline/rm_nucleo.csv` (editável); demais = periferia, com sub-anel opcional por contiguidade.

Migração intrametropolitana (data fixa): fluxos `o→d` com `o` e `d` na mesma RM, classificados em núcleo→periferia, periferia→núcleo e periferia→periferia; balanço da RM com o resto do país (entradas, saídas, saldo externo) e saldo interno por município; mesma tipologia de status, escolaridade, renda e idade/sexo do restante do atlas; seleção de fluxo com o mesmo painel de perfil.

Pendular para trabalho: universo = ocupados de 10+ anos (`P0960` = 1). Fluxo `o→d` = `P1120` = 3 com `P1140` conhecido e $\neq$ `P0080` ; `P1120` = 4 (outro país) e = 5 (vários municípios) contabilizados como categorias sem destino; `P1120` $\in$ {1,2} = trabalha no município. Caracterização completa de cada fluxo:

- frequência: retorno diário (`P1160` = 1) vs semanal/longa (`P1160` = 2);
- modo de transporte (`P1170` agrupado em 6: a pé/bicicleta; moto/mototáxi; automóvel/táxi; ônibus/van/BRT; trem/metrô; embarcação/outros) e tempo (`P1180` em 7 classes; mediana de `P1190`);
- inserção ocupacional: posição/formalidade (`P1020` em 5 grupos), grande grupo ocupacional (`P1040` , 11), setor (`P1030` em 8 grupos), rendimento do trabalho (`P1080` em 5 classes de SM);
- perfil demográfico: escolaridade (`P0770` , 25+), idade/sexo. Indicadores municipais: taxa de saída pendular (% dos ocupados residentes que trabalham fora), entradas de trabalhadores, saldo pendular, índice de atração (`trabalhadores no município / ocupados residentes`), % com retorno diário, tempo mediano, % transporte coletivo.

Pendular para estudo: universo = frequenta escola (`P0650` = 1). Fluxo `o→d` = `P0800` = 2 com `P0820` conhecido; caracterização por nível do curso (`P0660` em 4: infantil/fundamental, médio/EJA, graduação, pós-graduação) e idade/sexo.

Migrantes intrametropolitanos que fazem deslocamento pendular (cruzamento migração × pendularidade, na mesma pessoa): para cada migrante intra-RM (origem `o` = `P0620` , residência `d` = `P0080` , ambos na RM), registra-se o local de trabalho `w` (`P1140` , se `P1120` = 3 ; "no próprio município" se `P1120` $\in$ {1,2} ; "vários municípios"/"outro país" se `P1120` $\in$ {5,4}) e, para quem estuda, o local de estudo (`P0820`). Saídas:

- por RM e por município de residência `d` : migrantes intra-RM, quantos ocupados, quantos pendulares (e % dos ocupados), e a distribuição dos destinos de trabalho `w` com três classes analíticas — **volta a trabalhar no município de origem** (`w` = `o`), **trabalha no núcleo** (`w` = `núcleo` , `w` $\neq$ `o`), **outro município** — mais a lista dos principais `w` ;
- por fluxo migratório intra-RM `o→d` : % pendulares e principais destinos de trabalho (publicado só com `n` $\geq$ 20 , R2);
- tripla `o→d→w` agregada (`rm_mig_pendular.parquet`) para o diagrama aluvial "morava em (2017) → mora em (2022) → trabalha em (2022)";
- o espelho: entre os pendulares da RM, a parcela que é migrante recente (intra-RM, vinda de fora da RM, não migrante). Análogo simplificado para estudo (`o→d→escola`). Isso responde à pergunta clássica da desconcentração metropolitana: quem se mudou do núcleo para a periferia continua trabalhando no núcleo?

Ambos os módulos pendulares são calculados para o Brasil inteiro (permite mostrar fluxos que cruzam o limite da RM e medir sua extensão funcional), mas a seção do dashboard foca a RM selecionada. Precisão e supressão seguem as mesmas regras (se/CV por fluxo; regras R1–R9).

Conformidade com a política de acesso controlado do IBGE

Aviso honesto: não é possível dar garantia jurídica. O que o plano faz é (a) aderir a tudo o que a Nota 03/2026 e o fluxo de autorização exigem, (b) adotar controle estatístico de revelação mais conservador que o usual em tabulações de amostra, com trava automática no build, e (c) separar o que só o titular do acesso pode verificar. Os termos assinados (Termo de Compromisso de Confidencialidade e Responsabilidade; Termo de Uso e Finalidade) **não estão na pasta dos microdados** e devem ser guardados em `docs/termos/` (`gitignored`) como referência do projeto.

O que a política exige (Notas 03/2026, pp. 9–11) e como o plano responde:

Obrigação	Resposta do projeto
Usar os microdados exclusivamente para a finalidade declarada na solicitação	O dashboard é resultado agregado de estudo estatístico; o usuário confirma que a finalidade declarada cobre divulgação pública de resultados agregados (ver "Ações do titular")
Não alterar, compartilhar, redistribuir, ceder os arquivos; não publicar em repositórios ou nuvem	Arquivos brutos ficam só no disco local (symlink <code>data/raw</code>); <code>.gitignore</code> bloqueia <code>data/raw</code> , <code>data/interim</code> e qualquer <code>*.csv</code> ; repositório e site recebem apenas <code>data/processed</code> aprovado pelo gate; nenhum colaborador recebe cópia — cada um solicita o próprio acesso ao IBGE
Não usar para fins comerciais/publicitários	Site aberto, sem monetização, com licença de dados que remete ao IBGE
Reconhecer mecanismos de rastreabilidade e não tentar removê-los	Nada é feito sobre os arquivos além de leitura; nenhuma cópia derivada em nível de registro é distribuída
IBGE pode solicitar informações sobre os usos	Código auditável, <code>docs/METODOLOGIA.md</code> e <code>docs/relatorio_revelacao_<versao>.md</code> gerados a cada build servem de evidência
Resultados podem divergir dos oficiais; omitir dado que individualize ("x")	Rodapé padrão de fonte e aviso; regras R1–R9 abaixo

Regras de revelação (aplicadas em `06_disclosure.sql` e verificadas por `pipeline/disclosure_check.py`)

- **R1 Limiar:** toda célula publicada (fluxo, categoria dentro de fluxo, célula de perfil municipal ou de RM, indicador pendular) exige $n \geq 5$ pessoas e ≥ 3 domicílios distintos na amostra; abaixo disso a célula é suprimida ("x") e fundida em "outras origens/destinos" ou "outros".
- **R2 Detalhamento condicionado:** o perfil por características de um fluxo só é publicado se o fluxo tiver $n \geq 20$; abaixo, publica-se apenas o total com CV.
- **R3 Supressão complementar:** quando uma categoria de uma distribuição é suprimida, a segunda menor também é (ou ambas são fundidas), e as margens são conferidas nas duas dimensões, para impedir recuperação por diferença.
- **R4 Arredondamento:** estimativas ponderadas publicadas em múltiplos de 5; percentuais com uma casa decimal; nenhum peso individual ou soma de poucos pesos aparece.
- **R5 n em faixas:** o site exibe o número de observações amostrais em faixas (`20–49`, `50–99`, `100–499`, ≥ 500) e nunca o valor exato quando $n < 50$; o CV é sempre publicado.

- **R6 Geografia e cruzamentos:** menor unidade publicada = município (a APOND, permitida no arquivo, não é usada em saída alguma); só as dimensões pré-definidas (status 4, escolaridade 4, renda 5, idade-sexo 10; pendular: retorno 2, transporte 6, tempo 7, posição 5, ocupação 11, setor 8, rendimento 5) e nunca cruzamentos de três ou mais dimensões temáticas por município ou por fluxo. Única tripla geográfica permitida: origem migratória → residência → local de trabalho/estudo dentro de RM, sujeita a R1–R3 (detalhe só com $n \geq 20$).
- **R7 Dados-fonte:** `raw/interim` nunca em repositório, nuvem, Artifact, anexo de prompt ou subagente remoto; o pipeline roda apenas na máquina local.
- **R8 Gate automatizado:** `disclosure_check.py` roda antes de qualquer cópia para `web/public/data` e no CI; falha o build se qualquer célula violar R1–R6 e grava `docs/relatorio_revelacao_<versao>.md` (células suprimidas por tabela, limiares usados, hash dos arquivos publicados).
- **R9 Atribuição e aviso:** rodapé fixo — "Fonte: IBGE, Censo Demográfico 2022, microdados da amostra (acesso controlado). Estimativas elaboradas pelo autor, sujeitas a erro amostral e a controle estatístico de revelação; podem divergir das tabulações oficiais do IBGE (SIDRA)" — e página de metodologia com as regras acima.

Regras de trabalho para as sessões de implementação (entram no `CLAUDE.md`)

- Nunca imprimir registros individuais dos CSV/Parquet brutos em saídas de ferramentas (sem `head` além do cabeçalho, sem `SELECT * ... LIMIT`); só esquemas, contagens e distribuições agregadas com $n \geq 5$.
- Não copiar trechos dos arquivos para prompts, arquivos de contexto, Artifacts ou subagentes em nuvem; subagentes locais só recebem instruções e caminhos.
- Nenhum arquivo de dados é commitado sem passar pelo gate; `pre-commit` recusa `*.csv` e qualquer arquivo em `data/raw` ou `data/interim`.

Ações do titular do acesso (só você pode fazer)

1. Rer o Termo de Uso e Finalidade: se a finalidade declarada não menciona divulgação pública de resultados agregados (atlas/dashboard), solicitar ao IBGE, pelo mesmo canal da concessão, o registro/aditamento da finalidade antes de publicar, e guardar a resposta em `docs/termos/`.
2. Guardar cópia dos termos assinados e do e-mail de concessão em `docs/termos/` (gitignored).
3. Não compartilhar os arquivos com coautores; cada um solicita acesso próprio.
4. Antes do deploy (F7), assinar o checklist de conformidade: gate verde, relatório de revelação arquivado, repositório sem dados brutos, rodapé de fonte presente, finalidade confirmada.

Arquitetura

```
migracoes-fluxo-saldo-br/
├── CLAUDE.md                # convenções, caminhos, comandos, regras de sigilo
├── README.md
├── docs/METODOLOGIA.md      # definições acima + limitações
├── docs/termos/             # (gitignored) termos assinados e e-mail de concessão do IBGE
├── docs/relatorio_revelacao_<versao>.md # evidência do gate a cada build
├── pipeline/                # Python 3.14 (.venv) + DuckDB
│   ├── config.py            # caminhos, cortes de renda/idade, limiares de CV e n
│   ├── labels.py            # dicionários gerados das planilhas de codificação
│   ├── sql/01_extract.sql    # read_csv_auto sobre */Pessoas_*.csv + join Domicilios → interim/
│   ├── sql/02_classify.sql   # status, escolaridade, renda, idade → interim/migrantes.parquet
│   ├── sql/03_indicators.sql # municipios.parquet (+ long por dimensão)
│   ├── sql/04_flows.sql      # fluxos.parquet + agregações RGI/RGInt/UF
│   ├── sql/05_variance.sql   # se/cv por município e por fluxo
│   └── sql/06_disclosure.sql # regras R1-R6 (limiares, supressão complementar, arredondamento,
faixas de n)
│   ├── sql/07_pendular.sql   # fluxos pendulares trabalho/estudo + indicadores municipais
│   ├── sql/08_metro.sql      # recortes RM/CU, núcleo-periferia, resumo por RM
│   ├── rm_nucleo.csv         # município-sede por RM (editável)
│   ├── run.py                # orquestra as etapas com logs e checagens
│   ├── validate.py           # testes de consistência (ver Verificação)
│   └── disclosure_check.py    # gate R1-R6; gera docs/relatorio_revelacao_<versao>.md; falha o
build
├── tests/                   # pytest sobre DF/RO
├── geo/                     # scripts mapshaper: malha 2022 → TopoJSON + centroides
├── data/ (gitignored: raw→symlink, interim/) ; processed/ (publicável)
├── web/                     # Vite + React + TS
│   ├── public/data/         # cópia de data/processed + geo/*.topojson + meta.json
│   └── src/{app,components,map,charts,db,state,styles}
```

Contratos de dados (data/processed)

- `municipios.parquet` (5.570 linhas): `cd_mun`, `nm_mun`, `uf`, `cd_rgi`, `cd_rgint`, `pop`, `pop5`, `imig`, `imig_se`, `imig_ni`, `imig_int`, `emig`, `emig_se`, `saldo`, `saldo_se`, `tbi`, `tbe`, `tln`, `iem`, `n_imig`, `n_emig`, `cv_imig`, `cv_emig`, `cv_saldo`.
- `municipios_dim.parquet` (formato longo): `cd_mun`, `direcao(imig|emig|residente)`, `dimensao(status|edu|renda|idade-sexo)`, `categoria`, `valor`, `n`.
- `fluxos.parquet` (~150–300 mil linhas, formato largo): `origem`, `destino`, `total`, `se`, `cv`, `n`, `flag_sup`, `st_1..st_4`, `edu_1..edu_4`, `ren_1..ren_5`, `ren_na`, `is_1..is_10` (contagens ponderadas arredondadas).
- `fluxos_rgi.parquet`, `fluxos_rgint.parquet`, `fluxos_uf.parquet` (mesmo esquema, agregados) e `top_fluxos.json` (top 2.000 nacionais para o primeiro paint).
- `geo/municipios.topojson` (simplificado, alvo ≤ 2 MB), `geo/uf.topojson`, `geo/centroides.parquet`.
- `meta.json`: rótulos, cortes, limiares, versão dos dados, data de geração.
- Módulo metropolitano**: `rm.parquet` (`cod_rm`, `nome_rm`, `tipo(RM|RIDE|CU)`, `cd_mun`, `nucleo`, `pop`), `rm_resumo.parquet` (por RM: população, migração intra/entradas/saídas/saldo externo, matriz núcleo×periferia, ocupados, pendulares, % retorno diário, tempo mediano, % coletivo), `pendular_trab.parquet` (`origem`, `destino`, `total`, `se`, `cv`, `n`, `flag_sup`, `ret_1..2`, `modo_1..6`, `tempo_1..7`, `tempo_mediano`, `pos_1..5`, `ocup_1..11`, `setor_1..8`, `rend_1..5`, `edu_1..4`, `is_1..10`), `pendular_est.parquet` (`origem`, `destino`, `total`, `se`, `cv`, `n`, `flag_sup`, `nivel_1..4`, `is_1..10`), `municipios_pendular.parquet` (indicadores municipais de trabalho e estudo, com `se`), `rm_mig_pendular.parquet` (`cod_rm`, `origem_mig`, `destino_mig`, `destino_trab`,

`classe(origem|nucleo|outro|proprio|varios|exterior), total, se, n, flag_sup, ret_diario, modo_coletivo), rm_mig_pendular_resumo.parquet` (por RM e município de residência: migrantes intra-RM, ocupados, pendulares, pendular_para_origem, pendular_para_nucleo, pendular_outros, estudantes pendulares, com `se` e `n`) e `rm_mig_estudo.parquet` (tripla `o→d→escola`).

Web

- Estado da aplicação na URL (município, métrica, filtros, nível) para deep-linking; store leve (Zustand).
- `db/` : DuckDB-WASM em worker; carrega os Parquet uma vez (`registerFileBuffer`) e expõe `useQuery(sql, params)` ; todas as agregações/filtros são SQL local (instantâneo).
- `map/` : MapLibre GL sem basemap externo (polígonos + limites de UF + rótulos próprios, visual cartográfico limpo e sem dependência de terceiros) + `deck.gl MapboxOverlay: GeoJsonLayer` coroplético (saldo/TLM/IEM/volume, escala divergente centrada em 0, classes por quantis/Jenks), `ArcLayer` (largura $\propto$ volume, cor por direção entrada/saída, opacidade por confiabilidade), `ScatterplotLayer` opcional para I/E.
- `charts/` : Observable Plot para perfis (barras empilhadas 100% comparando imigrantes $\times$ emigrantes $\times$ residentes não migrantes), ranking, tabela top-N com barras embutidas; `d3-chord` para matriz UF $\times$ UF.
- Vistas: (1) Nacional — mapa + ranking + top fluxos; (2) Município — KPIs com IC, arcos top-N (slider), tabela de origens/destinos, perfil dos migrantes; (3) **Fluxo selecionado** — clicar em um arco (ou numa linha da tabela, para acessibilidade) fixa o par origem→destino e abre um painel com: volume, IC e `n` ; fluxo reverso `d→o` e saldo do par; perfil dos migrantes desse fluxo (status, escolaridade 25+, renda per capita, idade/sexo) em barras 100% comparadas com três referências — todos os imigrantes do destino, todos os emigrantes da origem e a população residente do destino; aviso visual quando `n` é pequeno ($CV > 30\%$), `n` exibido em faixas e supressão conforme R1–R3; hover realça o arco e mostra tooltip resumido; (4) Filtro por característica (escolaridade/renda/status) aplicado a mapa+arcos+tabelas; (5) Nível de agregação (município/RGI/RGInt/UF) — a seleção de fluxo funciona em qualquer nível; (6) **Regiões Metropolitanas** — seletor de RM/RIDE (ordenado por população, com busca; toggle para Concentrações Urbanas); mapa com zoom automático na RM, núcleo destacado e periferia; abas *Migração intrametropolitana* | *Pendular trabalho* | *Pendular estudo*; arcos intra-RM com opção de exibir fluxos que cruzam o limite da RM; matriz núcleo $\times$ periferia; ranking de municípios (saldo intra-RM, taxa de saída pendular, índice de atração, tempo mediano); seleção de fluxo com o mesmo painel de perfil — na aba pendular o painel traz frequência de retorno, modo de transporte, tempo, posição/formalidade, grupo ocupacional, setor, rendimento do trabalho, escolaridade e idade/sexo; painel comparativo entre RMs (small multiples de pendularidade, tempo mediano, % coletivo, saldo migratório interno/externo); na aba de migração intra-RM, o sub-painel **"Migrantes e trabalho"** mostra KPIs (quantos migrantes intra-RM estão ocupados, quantos fazem pendular, % que volta a trabalhar no município de origem, % que trabalha no núcleo), um diagrama aluvial *morava em* $\rightarrow$ *mora em* $\rightarrow$ *trabalha em* com os principais caminhos da RM, e, quando um fluxo migratório `o→d` está selecionado, a lista dos destinos de trabalho desses migrantes com barras e faixas de `n` ; (7) Metodologia e precisão; busca por município; exportar CSV/PNG.
- Interação com arcos (`deck.gl ArcLayer` + `pickable`): hover realça e esmaece os demais; clique fixa a seleção e atualiza a URL (`?o=3550308&d=2927408`); Esc/clique no vazio limpa; a mesma seleção é disparada pela tabela e pela busca "de ... para ...".
- Design: seguir a skill `dataviz` (paleta validada, marcas, interação, tema claro/escuro), tipografia e espaçamento consistentes, acessibilidade (contraste, foco, teclado), responsivo.

Fases (escalonadas)

Fase	Entregável	Critério de aceite	Sessões	Modelo principal
F0 Fundações	Repo, .venv (duckdb, pyarrow), brew install duckdb (CLI de reserva), npx mapshaper, symlink data/raw, .gitignore + pre-commit bloqueando dados brutos, CLAUDE.md com as regras de sigilo das sessões, labels.py gerado das planilhas, docs/METODOLOGIA.md v0, docs/termos/ criado, download da malha municipal 2022 (IBGE geoftp)	duckdb lê 53/Pessoas_53_controlado.csv e reproduz soma de pesos = 2.817.381; git add de um CSV é recusado pelo hook	1	Sonnet 5 (setup) + Opus 5 (revisão da metodologia)
F1 Extração	01_extract.sql: varre 27 UFs com read_csv (colunas tipadas como VARCHAR para códigos), seleciona ~30 colunas, join Domicilios (D0360, D0130, D0090), grava interim/pessoas.parquet (particionado por UF) e interim/domicilios_apond.parquet (n_h por APOND)	$\Sigma P0111 = 203.080.756$ (tolerância de arredondamento); por UF bate com Tabela 3; distribuição de P0600 plausível; 100% de P0620 na lista de municípios; tempo < 15 min	1	Sonnet 5; Opus 5 valida o SQL
F2 Indicadores e fluxos	02 – 06.sql: classificação de status/escolaridade/renda/idade, municipios*.parquet, fluxos*.parquet, variância, regras R1-R6 e disclosure_check.py; validate.py; relatório QA em markdown (top-30 fluxos, saldos extremos, comparação com padrões conhecidos SP↔NE, RM Brasília, fronteira agrícola)	Identidade $\Sigma imig = \Sigma emig$; nenhum fluxo com origem = destino; CVs coerentes com a FGV do IBGE em ordem de grandeza; gate de revelação verde com relatório gerado; testes pytest verdes	2	Table 5.1/Opus 5 para o SQL de classificação e variância; Haiku 4.5 para testes e relatório
F2b Pendular e recortes metropolitanos	07_pendular.sql (trabalho e estudo: fluxos com caracterização completa, indicadores municipais, se/CV, supressão) e 08_metro.sql (rm.parquet, rm_nucleo.csv, matriz núcleo×periferia, rm_resumo.parquet, cruzamento migração intra-RM × pendularidade: rm_mig_pendular*.parquet, rm_mig_estudo.parquet); QA: top pares pendulares por RM, % pendular por RM vs. resultados publicados do Censo 2022 sobre deslocamento para trabalho, % de migrantes núcleo→periferia que seguem trabalhando no núcleo nas RMs de SP/RJ/BH	Σ saídas pendulares (destino conhecido) = Σ entradas; universo = ocupados 10+ / estudantes; Santana→Macapá e Guarulhos→São Paulo entre os maiores pares; tripla o→d→w soma aos migrantes ocupados de cada o→d; testes verdes	2	Opus 5 (agrupamentos de transporte/ocupação/setor e definição de núcleo); Sonnet 5 para SQL

Fase	Entregável	Critério de aceite	Sessões	Modelo principal
F3 Geo	geo/build.sh : malha 2022 → TopoJSON simplificado (mapshaper, –simplify 8% keep-shapes), UF, centroides (ponto representativo), meta.json	5.570 ids casam 1:1 com municípios.parquet ; TopoJSON ≤ 2 MB; render < 100 ms	1	Sonnet 5
F4 Dashboard MVP	Scaffold Vite/React/TS, worker DuckDB-WASM, mapa coroplético com seleção, arcos top-N do município selecionado, painel de KPIs com IC, busca, estado na URL, layout base	Carga inicial ≤ 25 MB e < 3 s em banda larga; interação sem travar com 2.000 arcos; sem erros no console	2–3	Opus 5 (arquitetura, design system) + Sonnet 5 (componentes)
F5 Características e fluxo selecionado	Seleção de arco/linha com painel de perfil do fluxo o→d (volume, IC, reverso, saldo do par, barras 100% de status/escolaridade/renda/idade-sexo contra as três referências); filtros por escolaridade/renda/status (e idade/sexo) aplicados a mapa/arcos/tabelas; gráficos de perfil imigrantes × emigrantes × residentes; níveis RGI/RGIInt/UF; chord UF×UF; export CSV/PNG	Clique no arco abre o painel em < 200 ms; perfil do fluxo soma ao total do fluxo; cada filtro recalcula em < 200 ms; supressão e avisos de CV respeitados em todas as vistas	2–3	Sonnet 5; Opus 5 revisa lógica de agregação e a UX do painel de fluxo
F5b Módulo metropolitano	Seção "Regiões Metropolitanas": seletor de RM/CU, mapa com zoom e núcleo/periferia, abas migração intra-RM / pendular trabalho / pendular estudo, arcos intra-RM e transfronteiriços, matriz núcleo×periferia, rankings, painel de fluxo pendular com caracterização completa, sub-painel "Migrantes e trabalho" (KPIs, aluvial origem→residência→trabalho, destinos de trabalho do fluxo selecionado), comparativo entre RMs	Troca de RM em < 300 ms; painel de fluxo pendular soma ao total do fluxo; aluvial soma aos migrantes ocupados da RM; supressão e CV respeitados; RM de São Paulo, Rio, BH, Porto Alegre, Recife, Fortaleza, Salvador, Curitiba, RIDE-DF, Belém, Manaus e Goiânia revisadas visualmente	2–3	Opus 5 (arquitetura da seção e UX do painel pendular); Sonnet 5 (componentes)
F6 Refinamento	Passe de design (skill dataviz + design:design-critique), acessibilidade (design:accessibility-review), responsividade, tooltips/legendas com incerteza, página de metodologia, tour de onboarding, performance	Checklist de acessibilidade sem itens críticos; revisão visual aprovada pelo usuário	1–2	Fable 5.1/Opus 5 para crítica de design; Sonnet 5 executa
F7 Publicação	CI (GitHub Actions) que roda disclosure_check.py antes do build de web/ e publica em Pages; README com citação, licença e limitações; rodapé R9; checklist de conformidade assinado pelo titular (finalidade confirmada, termos arquivados, gate verde, relatório de revelação, repositório sem dados brutos); versão dos dados	Site público no ar; CI falha se o gate falhar; nenhum arquivo bruto/intermediário no repositório (verificado por varredura do histórico git)	1	Sonnet 5 / Haiku 4.5

Total estimado: 14–19 sessões de trabalho.

Extensões futuras (fora do escopo atual): migração de última etapa (P0580 / P0550), comparação com Censo 2010, fluxos por área de ponderação dentro das grandes metrópoles (o microdado controlado permite), estimativas de variância por bootstrap.

Orquestração de modelos Claude (custo-benefício)

Preços de referência (API, por milhão de tokens entrada/saída): Fable 5.1 US\$10/50; Opus 5 US\$5/25; Sonnet 5 US\$2/10; Haiku 4.5 US\$1/5. Em Claude Code o custo relativo é o mesmo (quota do plano).

Tipo de tarefa	Modelo	Por quê
Decisões metodológicas, SQL de classificação/variância, arquitetura do app, revisão crítica de design e de PRs	Opus 5 (padrão); Fable 5.1 só nos pontos mais difíceis (F2 variância, F6 crítica final)	Erros aqui custam retrabalho em todas as fases; Fable custa 2× Opus e só compensa onde o raciocínio é mais exigente
Implementação de componentes React, loaders, scripts de geo, SQL de agregação, documentação	Sonnet 5	Melhor razão qualidade/custo para código com especificação clara
Gerar <code>labels.py</code> das planilhas, escrever testes a partir de spec, formatar relatório QA, refatorações mecânicas, buscas no código	Haiku 4.5 (via subagente)	Tarefas determinísticas e bem especificadas; 1/10 do custo do Fable

Mecânica em Claude Code:

- Trocar o modelo da sessão pelo seletor do app (ou `/model`) por fase: F0/F1/F3/F4-componentes/F5/F5b-componentes/F7 em **Sonnet 5**; F2, F2b (definições) e F6 em **Opus 5**, escalando para Fable 5.1 apenas nos trechos indicados.
- Delegar tarefas mecânicas a subagentes com `model: "haiku" ou "sonnet"` (Agent tool), sempre com prompt autocontido apontando para `CLAUDE.md` e `docs/METODOLOGIA.md`.
- Uma fase por sessão; `CLAUDE.md` concentra convenções para que modelos mais baratos acertem de primeira; `/compact` antes de mudar de fase.
- Nível de esforço: `high` para F2/F6, `medium` para o restante. Não usar fast mode (custa mais, não economiza).
- Estimativa de mix de tokens: ~15% Opus/Fable, ~65% Sonnet, ~20% Haiku.

Verificação

Pipeline (`pipeline/validate.py` + `pytest` em DF e RO, < 1 min):

1. $\sum$ pesos por UF e Brasil = totais oficiais (Tabela 3 das Notas 04/2026).
2. $\sum imig$ (origem conhecida) = $\sum emig$ no Brasil; `saldo` soma zero.
3. Nenhum `origem = destino`; todos os códigos em `Codificação_Município`; `n ≥ 1` em todo fluxo; `flag_sup` coerente com R1–R3. 3b. Gate de revelação: `disclosure_check.py` varre todos os Parquet de `data/processed` e falha se existir célula publicada com `n < 5` pessoas ou `< 3` domicílios, perfil de fluxo com `n < 20`, distribuição com uma única categoria suprimida, valor não múltiplo de 5, `n` exato abaixo de 50, ou qualquer coluna de APOND/identificador de domicílio.
4. CV por município vs FGV: $cv_fgv = 4,0616 \cdot t^{-0,5004}$; razão mediana entre 0,5 e 2.
5. Reprodutibilidade: rodar duas vezes gera Parquet idêntico (hash).

6. Sanidade demográfica: SP, RJ, DF, Goiás, SC e PR entre os maiores volumes; retorno NE > média nacional; migrantes 25+ com superior completo em proporção maior que residentes.
7. Pendular: Σ saídas com destino conhecido = Σ entradas; universo restrito a ocupados ($P0960 = 1$) e estudantes ($P0650 = 1$); nenhum fluxo com `origem = destino`; % de ocupados que trabalham em outro município por UF em ordem de grandeza compatível com os resultados publicados do Censo 2022; tempo mediano intra-RM maior nas RMs de SP e RJ.
8. Metropolitano: todo município pertence a no máximo uma RM/RIDE; cada RM tem exatamente um núcleo; matriz núcleo×periferia soma ao total intra-RM; para cada fluxo intra-RM `o→d`, Σ tripla `o→d→w` (todas as classes) = migrantes ocupados do fluxo, e a classe "volta à origem" só existe quando `w = o`.

Dashboard: rodar `npm run dev` pelo preview do Claude Code e verificar visualmente (mapa, seleção, arcos, filtros, URL), console sem erros, medir payload e tempo de carga; testes de componentes (Vitest) para formatação de números/IC e SQL builders; revisão de acessibilidade (axe) e de contraste; build de produção servido localmente antes do deploy.

Riscos e mitigações

- Wheel do `duckdb/pyarrow` para Python 3.14 indisponível → usar DuckDB CLI (`brew install duckdb`) ou venv com Python 3.12 (`uv`).
- Memória: DuckDB processa os CSVs em streaming; 24 GB e 12 núcleos são suficientes. Definir `PRAGMA threads` e `memory_limit`.
- Download da malha IBGE indisponível → espelho `geobr`.
- DuckDB-WASM (~6–8 MB) e Safari → carregar em worker, mostrar progresso, fallback para `top_fluxos.json` no primeiro paint.
- Sigilo e conformidade: risco principal é a finalidade declarada não cobrir divulgação pública → confirmar/aditar junto ao IBGE antes do deploy; risco técnico de vazamento → `.gitignore`, `pre-commit`, gate R8 no CI e varredura do histórico git antes de tornar o repositório público; risco de revelação por diferença → R3 (supressão complementar) e R4 (arredondamento).
- RMs institucionais heterogêneas (muitas RMs estaduais sem integração funcional) → ordenar por população, sinalizar tipo (RM/RIDE) e oferecer o recorte funcional de Concentrações Urbanas como alternativa.
- `P1120 = 5` (trabalha em vários municípios) não tem destino → reportado como categoria própria, fora da matriz; `P1160 = 2` (não retorna 3+ dias) mantido nos fluxos com rótulo "semanal/longa", pois é deslocamento real, mas não diário.